

# Klassifizierung von E-Mails



# Klassifizierung von E-Mails

Mithilfe Künstlicher Intelligenz (KI)







Kleines IT-Unternehmen





- Kleines IT-Unternehmen
- Ohne Verwaltung





- Kleines IT-Unternehmen
- Ohne Verwaltung
- Modul zur Anbindung eines Mail-Servers





- Kleines IT-Unternehmen
- Ohne Verwaltung
- Modul zur Anbindung eines Mail-Servers

SYLVENSTEIN SOFTWARE













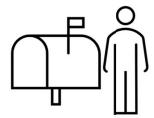
Allgemeines Postfach







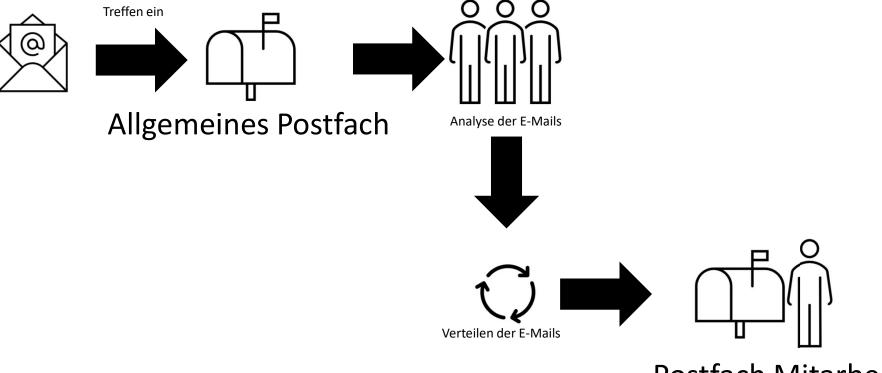
Allgemeines Postfach



Postfach Mitarbeiter



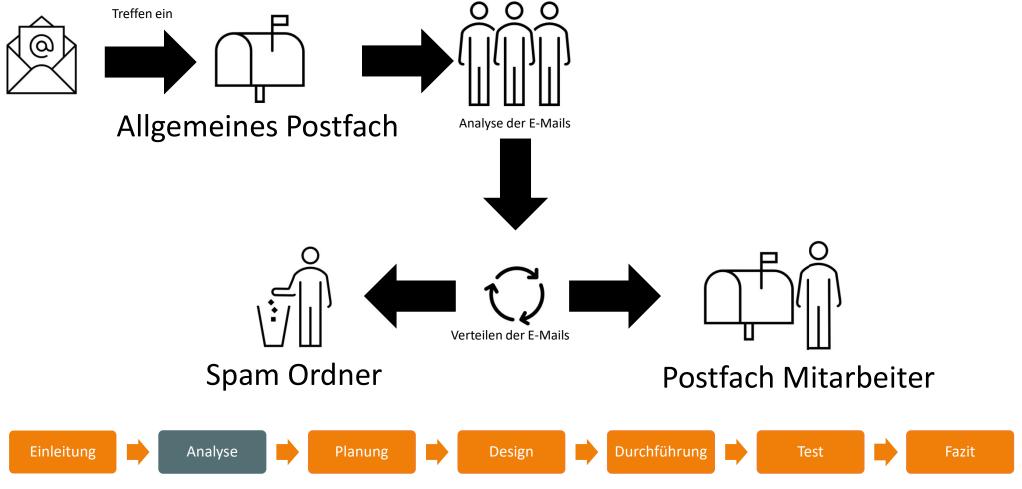


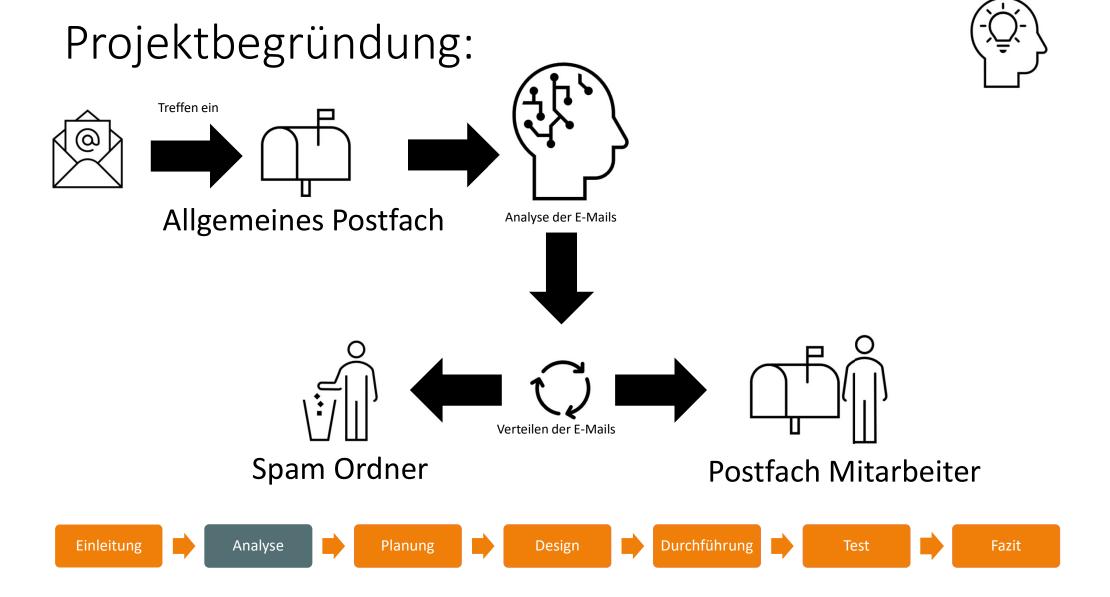


Postfach Mitarbeiter

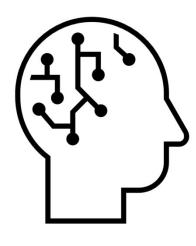
Einleitung Analyse Planung Design Durchführung Test Fazit











Wissenserwerb









Mail-Server







Mail-Server



Datenbank







Mail-Server



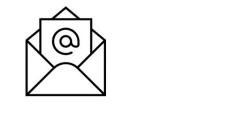
Datenbank

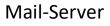


ΚI

Einleitung Analyse Planung Design Durchführung Test Fazit









Semi



Datenbank



ΚI

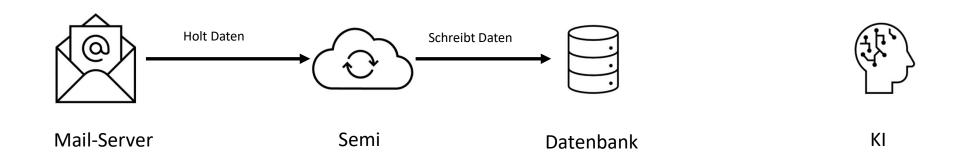






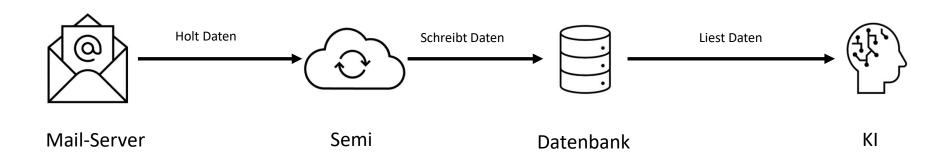






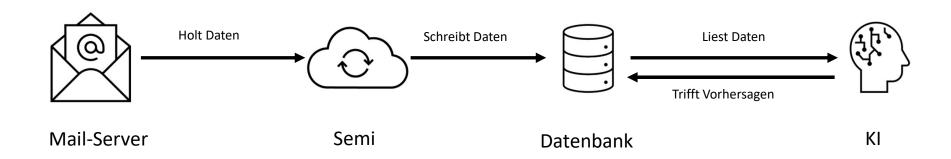






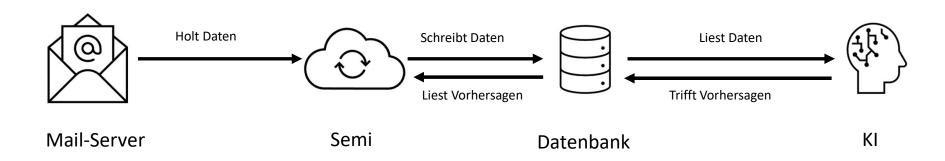






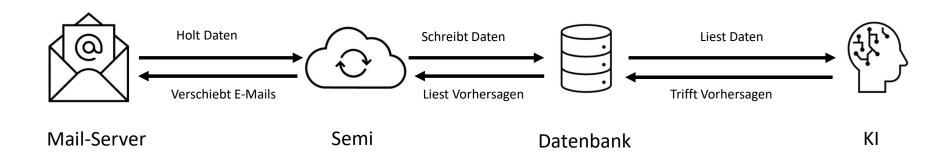


















• Weit verbreitet





Einleitung Analyse Planung Design Durchführung Test Fazit

Weit verbreitet





• Viele Bibliotheken



Einleitung Analyse Planung Design Durchführung Test Fazit

Weit verbreitet





• Viele Bibliotheken



KI-Bibliotheken







Einleitung

Analyse

<u>Pl</u>anung

Design

Durchführung

Fazit



Einleitung Analyse Planung Design Durchführung Test Fazit



Visualisierung der Datenverarbeitung





- Visualisierung der Datenverarbeitung
- Performance





- Visualisierung der Datenverarbeitung
- Performance
- Netzwerkschnittstelle (verschlüsselt)





- Visualisierung der Datenverarbeitung
- Performance
- Netzwerkschnittstelle (verschlüsselt)
- → Zentrale Schnittstelle zwischen Mail-Server & KI-Model







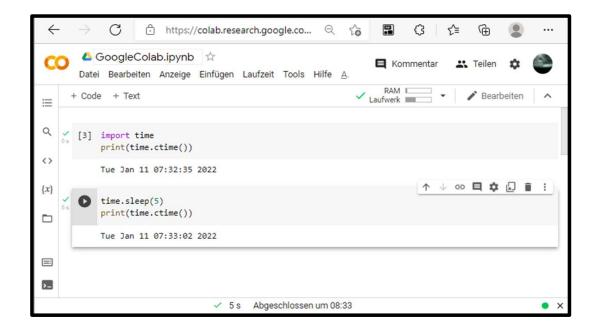






#### + Vorteile:

Cloud Computing Lösung







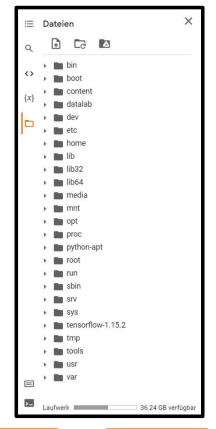
- Cloud Computing Lösung
- Kostenlose Rechenleistung







- Cloud Computing Lösung
- Kostenlose Rechenleistung
- Konfigurationszeit







- Cloud Computing Lösung
- Kostenlose Rechenleistung
- Konfigurationszeit
- Aktueller Standard







#### + Vorteile:

- Nachteile:

- Cloud Computing Lösung
- Kostenlose Rechenleistung
- Konfigurationszeit
- Aktueller Standard



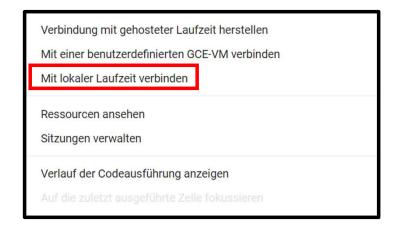


#### + Vorteile:

- Cloud Computing Lösung
- Kostenlose Rechenleistung
- Konfigurationszeit
- Aktueller Standard

#### - Nachteile:

Datenschutz (DSGVO)







#### + Vorteile:

- Cloud Computing Lösung
- Kostenlose Rechenleistung
- Konfigurationszeit
- Aktueller Standard

#### - Nachteile:

- Datenschutz (DSGVO)
- Serverstandort nicht frei wählbar





Einleitung Analyse Planung Design Durchführung Test Fazit



• Wichtiger Teilschritt bei KI-Projekten (NLP)





- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung





- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)

Mit Rauschen	Geräusch entfernt
#Ärger	Ärger
<a>Ärger<a></a></a>	Ärger
1.Ärger	Ärger



- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen

Mit Stoppwörter → "Wann ist der Banner fertig ?" Ohne Stoppwörter → "Wann Banner fertig"



- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)

Unbearbeitet	Lemma
Gut	Gut
Besser	Gut



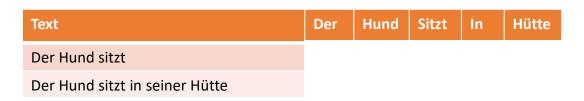
- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)
    - Stammformreduktion (Stemming)

Unbearbeitet	Lemma
Gut	Gut
Besser	Gut

Unbearbeitet	Stammform
Reduktion	Redu
Reduzieren	Redu
reduziertes	Redu



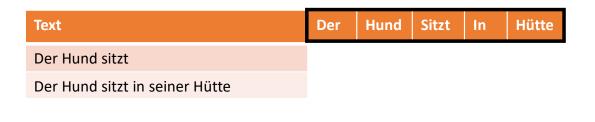
- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)
    - Stammformreduktion (Stemming)
  - Tokenisierung (Tokenization)







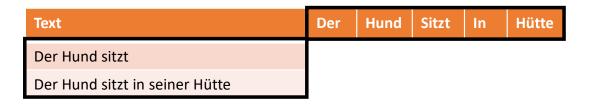
- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)
    - Stammformreduktion (Stemming)
  - Tokenisierung (Tokenization)







- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)
    - Stammformreduktion (Stemming)
  - Tokenisierung (Tokenization)







- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)
    - Stammformreduktion (Stemming)
  - Tokenisierung (Tokenization)

Text	Der	Hund	Sitzt	In	Hütte
Der Hund sitzt	1	1	1	0	0
Der Hund sitzt in seiner Hütte	1	1	1	1	1



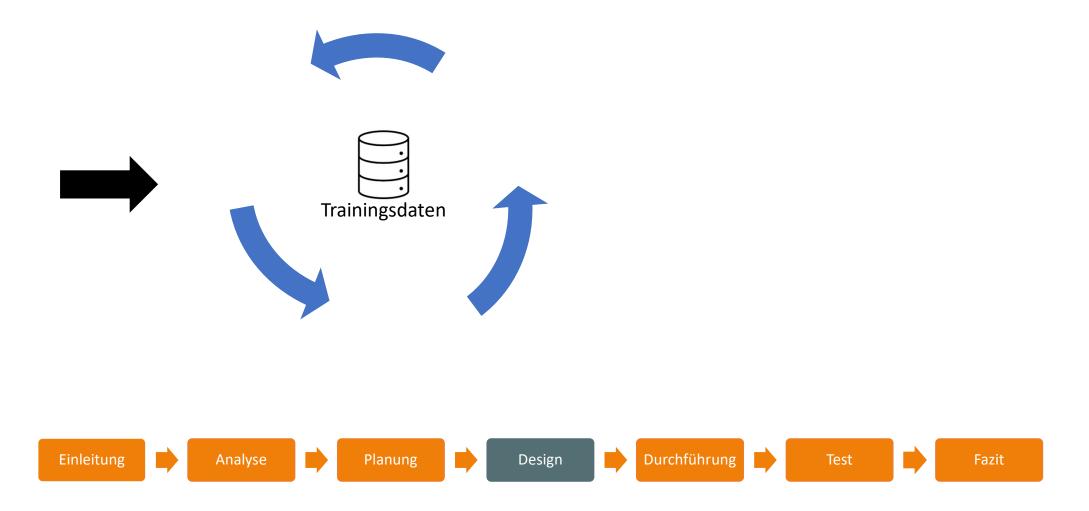


- Wichtiger Teilschritt bei KI-Projekten (NLP)
  - Normalisierung
    - Geräuschentfernung (Noise Removal)
    - Stoppwörter entfernen
    - Lemmatisierung (Lemmatisation)
    - Stammformreduktion (Stemming)
  - Tokenisierung (Tokenization)

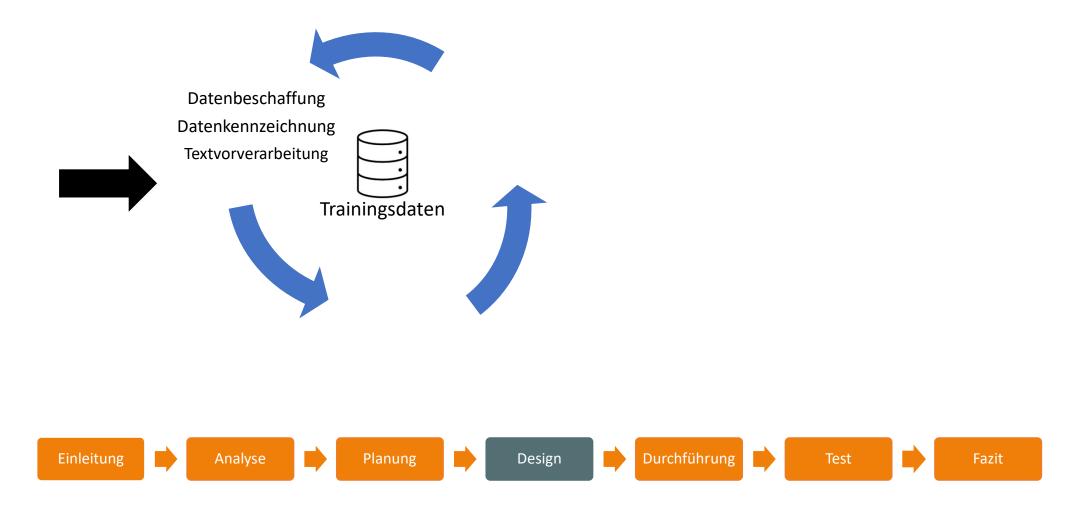
Text	Der	Hund	Sitzt	In	Hütte	Mit
Der Hund sitzt	1	1	1	0	0	0
Der Hund sitzt in seiner Hütte	1	1	1	1	1	0
Der Hund mit Hütte	1	1	0	0	1	1



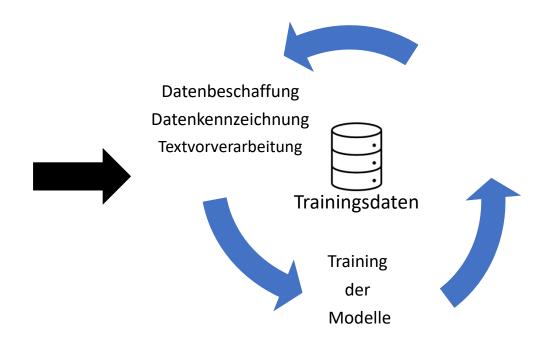






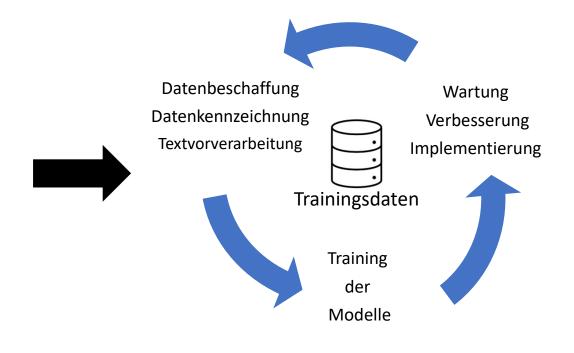




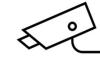


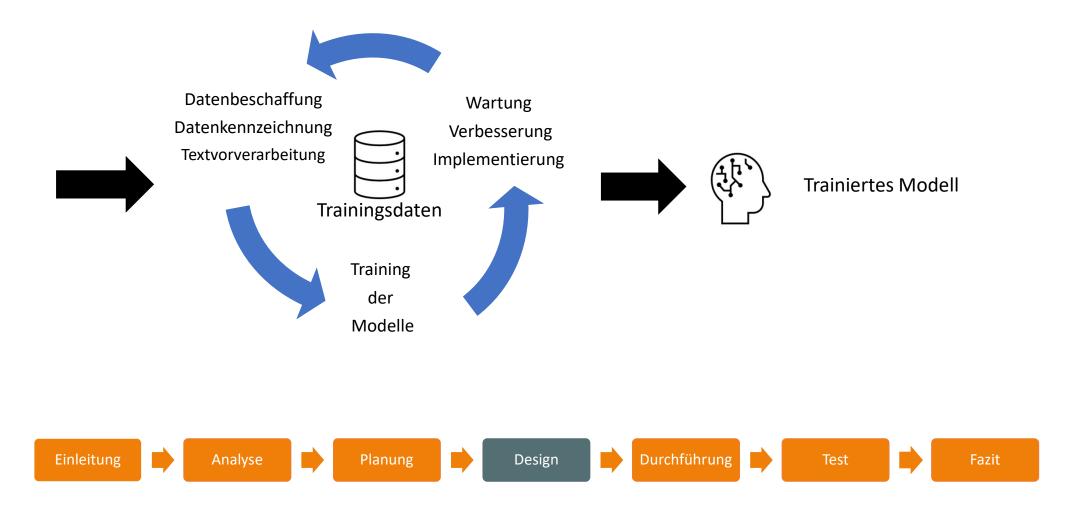




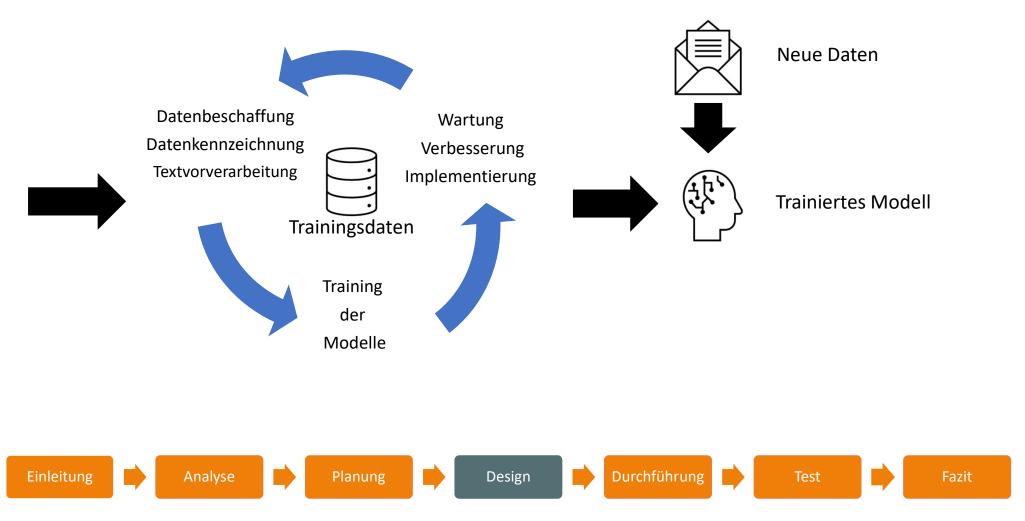




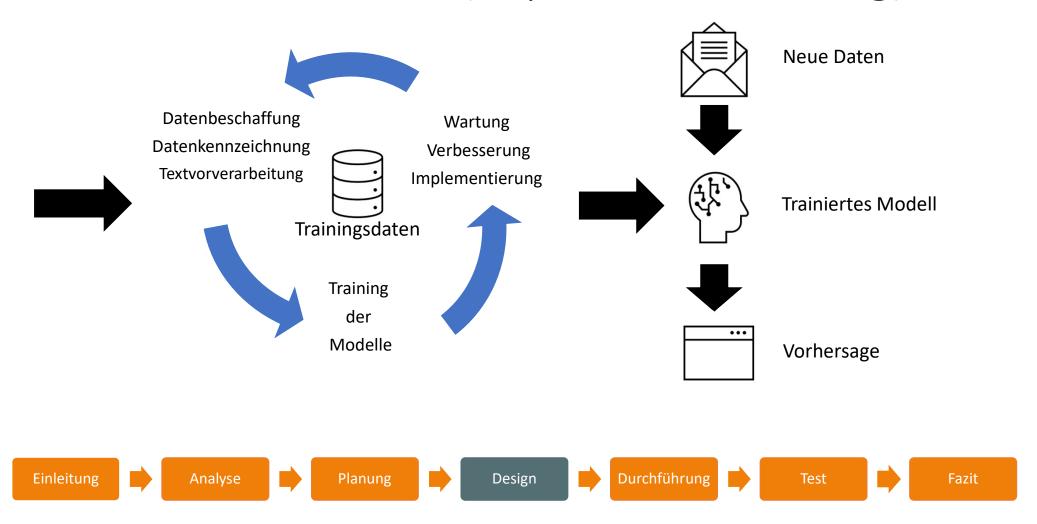


















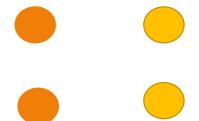








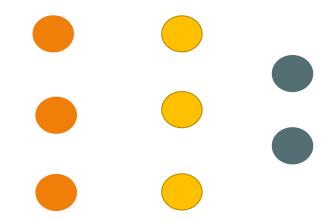






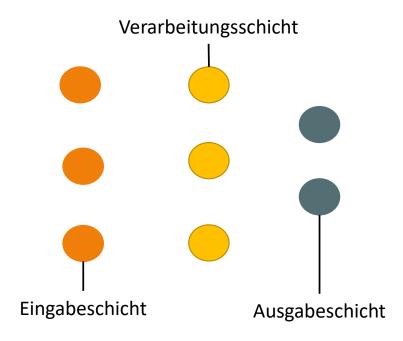
Einleitung Analyse Planung Design Durchführung Test Fazit







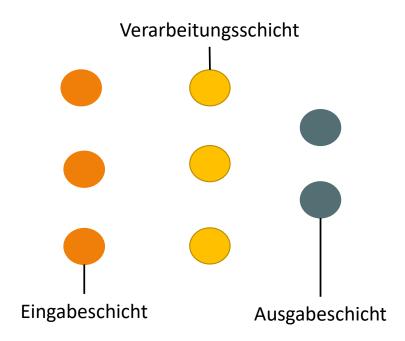






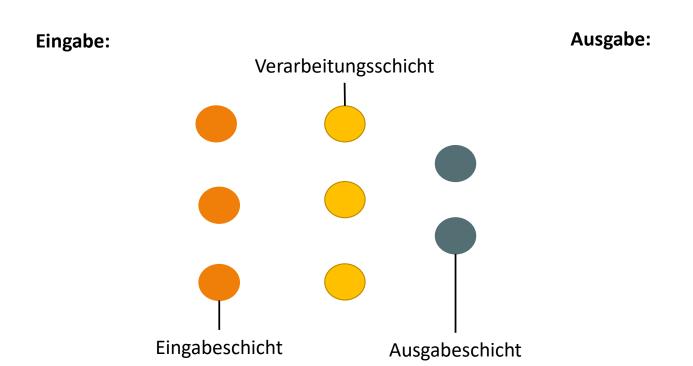


#### **Eingabe:**





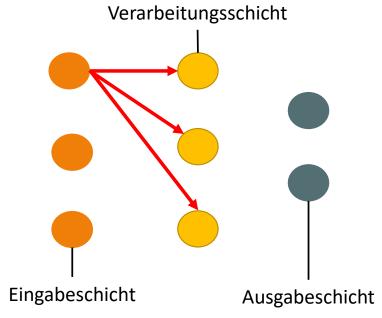






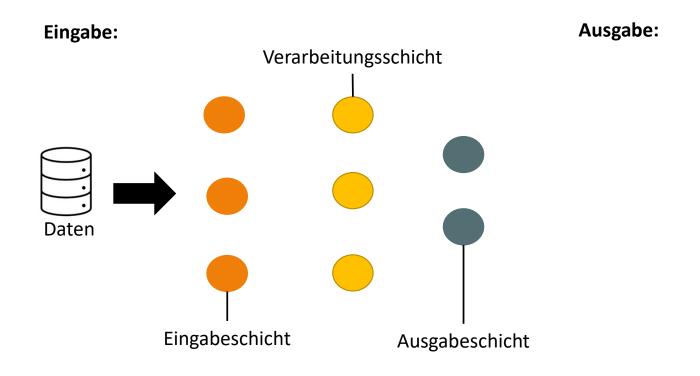




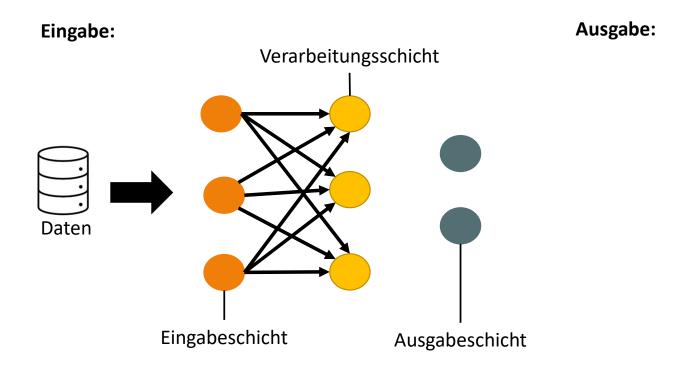






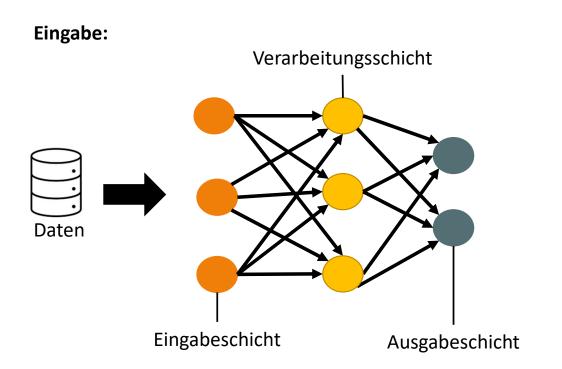






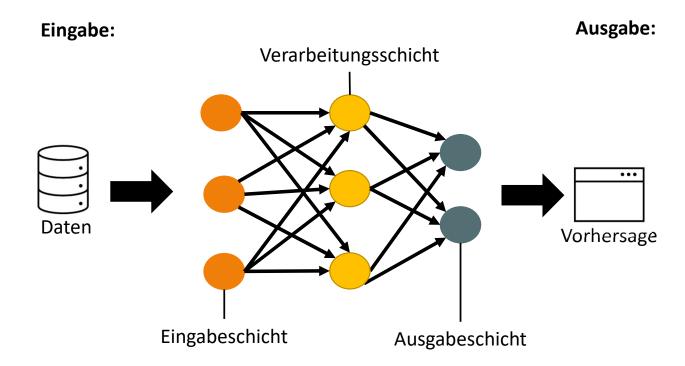






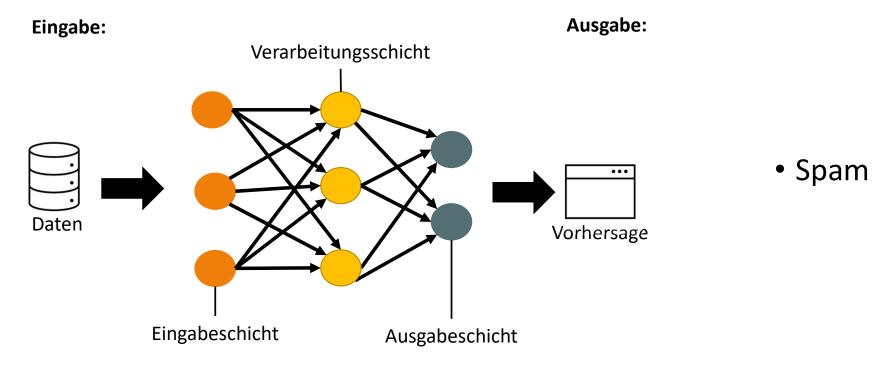
Ausgabe:



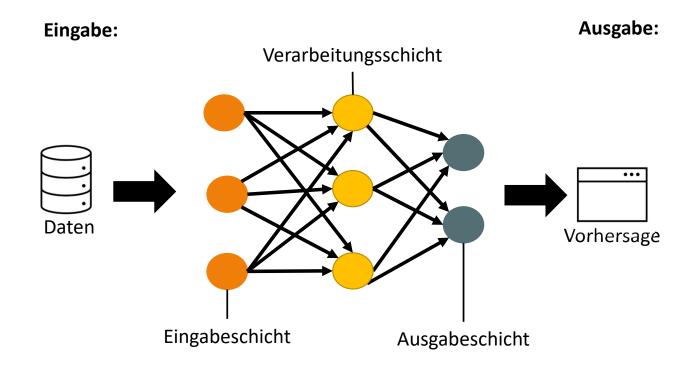












- Spam
- Themen





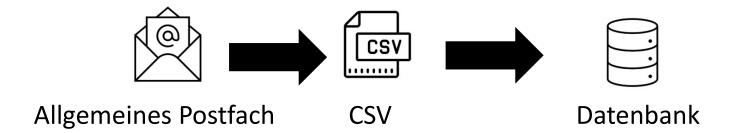
Allgemeines Postfach





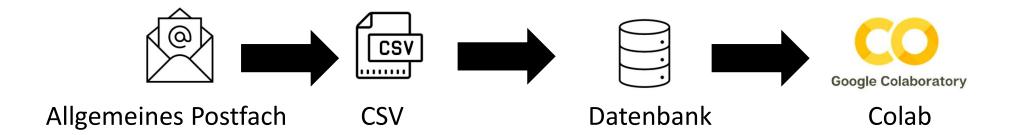






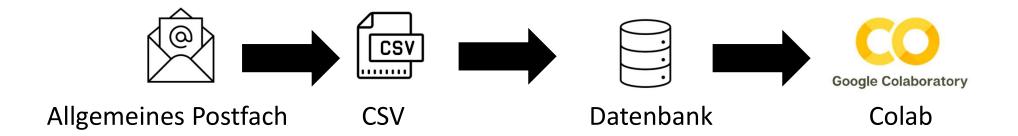








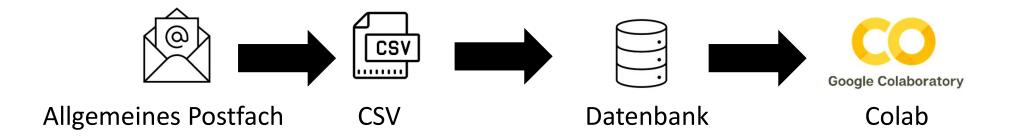




→ Repräsentative Auswahl an E-Mails



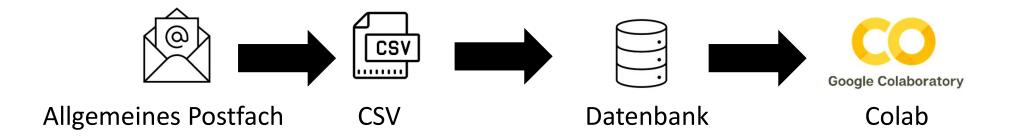




- → Repräsentative Auswahl an E-Mails
- → 150 E-Mails ausgewählt







- → Repräsentative Auswahl an E-Mails
- → 150 E-Mails ausgewählt
- → Randomisiert und vervielfältigt: 1500 Emails









#### Mitarbeiter Tabelle

ID	Name	Themen
1	Braun	Apps, Kunde





#### Mitarbeiter Tabelle

ID	Name	Themen
1	Braun	Apps, Kunde

ID	Absender	Empfänger	Betreff	Inhalt	
1	XY	XY	XYZ	Lorem Ipsum	





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	

ID	Absender	Empfänger	Betreff	Inhalt	
1	XY	XY	XYZ	Lorem Ipsum	





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

ID	Absender	Empfänger	Betreff	Inhalt	
1	XY	XY	XYZ	Lorem Ipsum	





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

ID	Absender	Empfänger	Betreff	Inhalt	 SPAM
1	XY	XY	XYZ	Lorem Ipsum	





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

ID	Absender	Empfänger	Betreff	Inhalt	 SPAM	TAGS
1	XY	XY	XYZ	Lorem Ipsum		





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

ID	Absender	Empfänger	Betreff	Inhalt	 SPAM	TAGS
1	XY	XY	XYZ	Lorem Ipsum	 0	





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

ID	Absender	Empfänger	Betreff	Inhalt	•••	SPAM	TAGS
1	XY	XY	XYZ	Lorem Ipsum	•••	0	AP, KU





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

ID	Absender	Empfänger	Betreff	Inhalt	 SPAM	TAGS
1	XY	XY	XYZ	Lorem Ipsum	 0	AP, KU





#### Mitarbeiter Tabelle

ID	Name	Themen	Tags
1	Braun	Apps, Kunde	AP, KU

#### E-Mails Tabelle

ID	Absender	Empfänger	Betreff	Inhalt		SPAM	TAGS
1	XY	XY	XYZ	Lorem Ipsum	•••	0	AP, KU

#### → Skalierbarkeit











Spam:







#### Spam:

```
# Eingabeschicht (Input-Layer)
```

# Verarbeitungsschicht (Hidden-Layer)

# Ausgabeschicht (Output-Layer)





#### Spam:

```
# Eingabeschicht (Input-Layer)
model.add(tf.keras.layers.Dense(256, input_shape=x_train.shape, activation='sigmoid'))
# Verarbeitungsschicht (Hidden-Layer)
# Ausgabeschicht (Output-Layer)
```







#### Spam:

```
# Eingabeschicht (Input-Layer)
model.add(tf.keras.layers.Dense(256, input_shape=x_train.shape, activation='sigmoid'))
# Verarbeitungsschicht (Hidden-Layer)
model.add(tf.keras.layers.Dense(256, activation='sigmoid'))
# Ausgabeschicht (Output-Layer)
```







#### Spam:

```
# Eingabeschicht (Input-Layer)
model.add(tf.keras.layers.Dense(256, input_shape=x_train.shape, activation='sigmoid'))
# Verarbeitungsschicht (Hidden-Layer)
model.add(tf.keras.layers.Dense(256, activation='sigmoid'))
# Ausgabeschicht (Output-Layer)
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))
```





#### Spam:

```
# Eingabeschicht (Input-Layer)
model.add(tf.keras.layers.Dense(256, input_shape=x_train.shape, activation='sigmoid'))
# Verarbeitungsschicht (Hidden-Layer)
model.add(tf.keras.layers.Dense(256, activation='sigmoid'))
# Ausgabeschicht (Output-Layer)
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))
OUT: Boolean
```





#### Thema:

```
# Eingabeschicht (Input-Layer)
```

# Verarbeitungsschicht (Hidden-Layer)

# Ausgabeschicht (Output-Layer)





#### Thema:

```
# Eingabeschicht (Input-Layer)
model.add(512, input_shape=x_train.shape, activation='sigmoid')
# Verarbeitungsschicht (Hidden-Layer)
# Ausgabeschicht (Output-Layer)
```





#### Thema:

```
# Eingabeschicht (Input-Layer)
model.add(512, input_shape=x_train.shape, activation='sigmoid')
# Verarbeitungsschicht (Hidden-Layer)
model.add(256, activation='sigmoid')
# Ausgabeschicht (Output-Layer)
```





#### Thema:

```
# Eingabeschicht (Input-Layer)
model.add(512, input_shape=x_train.shape, activation='sigmoid')
# Verarbeitungsschicht (Hidden-Layer)
model.add(256, activation='sigmoid')
# Ausgabeschicht (Output-Layer)
model.add(1, output_mode="multi_hot", activation="sigmoid")
```





#### Thema:

```
# Eingabeschicht (Input-Layer)
model.add(512, input_shape=x_train.shape, activation='sigmoid')
# Verarbeitungsschicht (Hidden-Layer)
model.add(256, activation='sigmoid')
# Ausgabeschicht (Output-Layer)
model.add(1, output_mode="multi hot", activation="sigmoid")
```

## KI-Modelle: Spam & Thema





#### Thema:

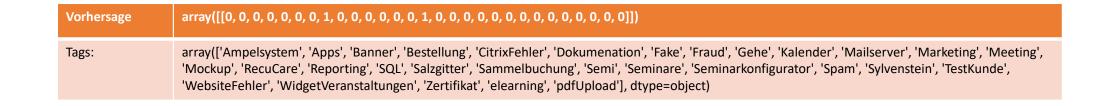
```
# Eingabeschicht (Input-Layer)
model.add(512, input_shape=x_train.shape, activation='sigmoid')
# Verarbeitungsschicht (Hidden-Layer)
model.add(256, activation='sigmoid')
# Ausgabeschicht (Output-Layer)
model.add(1, output_mode="multi hot", activation="sigmoid")
OUT: Bag of Words
```

Einleitung Analyse Planung Design Durchführung Test Fazit

## KI-Modelle: Spam & Thema





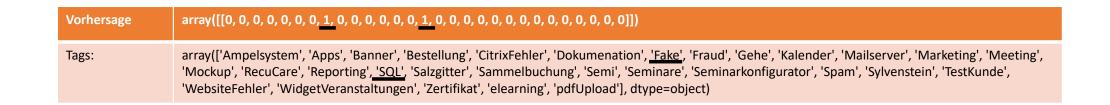




# KI-Modelle: Spam & Thema



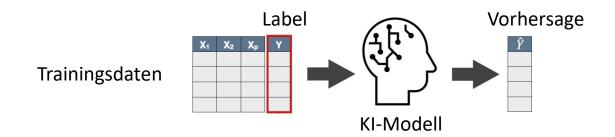






# Iteratives Training

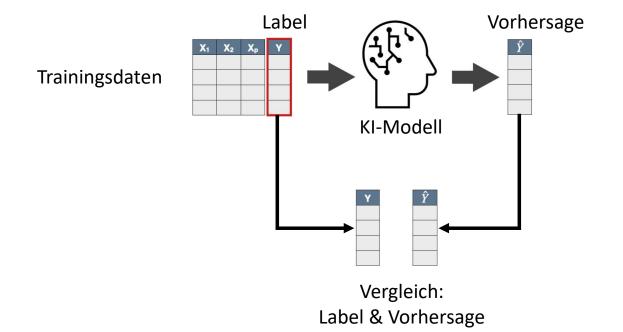






# Iteratives Training

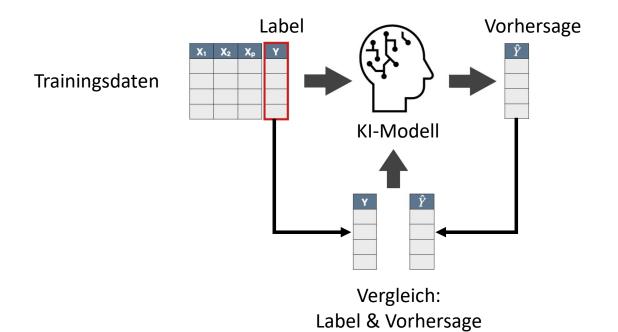




Einleitung Analyse Planung Design Durchführung Toman Fazit

# Iteratives Training





Einleitung Analyse Planung Design Durchführung Tom Test Fazit











Einleitung Analyse Planung Design Durchführung Test Fazit







Analyse

Planung

Einleitung



Fazit

Design

Durchführung

Test



#### Anpassung der Parameter innerhalb des Netzes

Einleitung Analyse Planung Design Durchführung Test Fazit



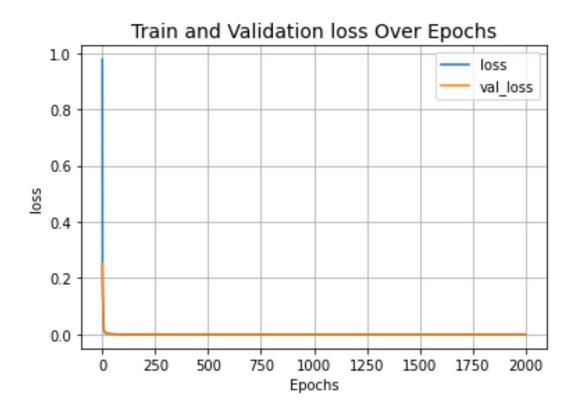
#### Anpassung der Parameter innerhalb des Netzes

```
Epoch 64/500
Epoch 65/500
Epoch 210/500
Epoch 211/500
Genauigkeit der Vorhersagen
```

Durchführung Einleitung Analyse Planung Fazit Design Test

## Lernkurve: Thema

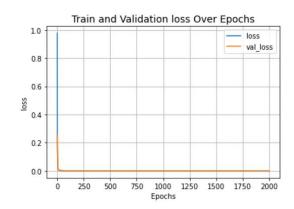


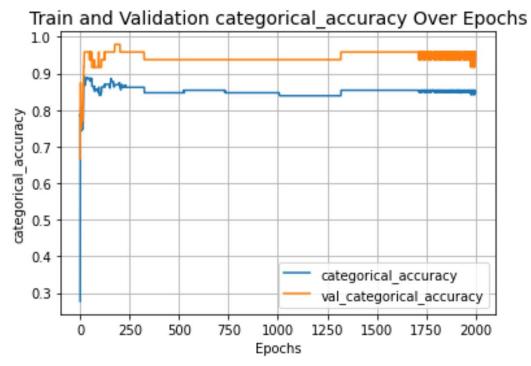




#### Lernkurve: Thema

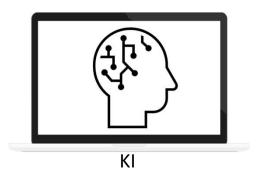








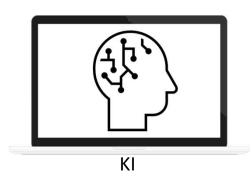




Einleitung Analyse Planung Design Durchführung Test Fazit

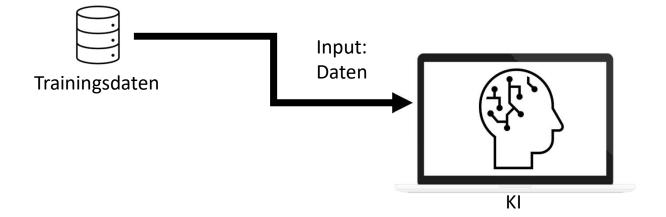






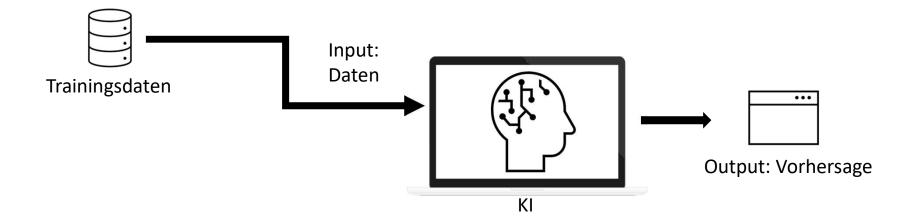
Einleitung Analyse Planung Design Durchführung Test Fazit



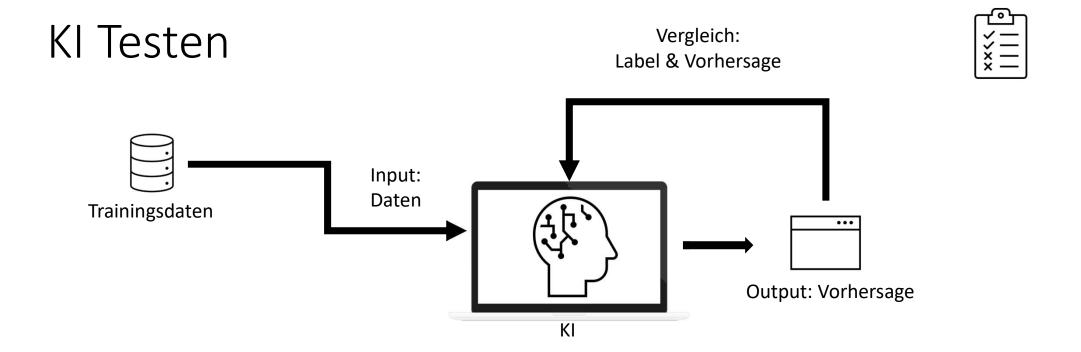






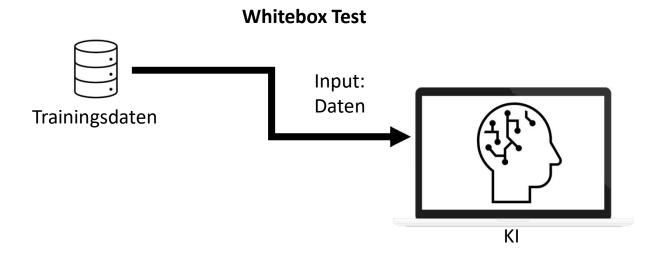






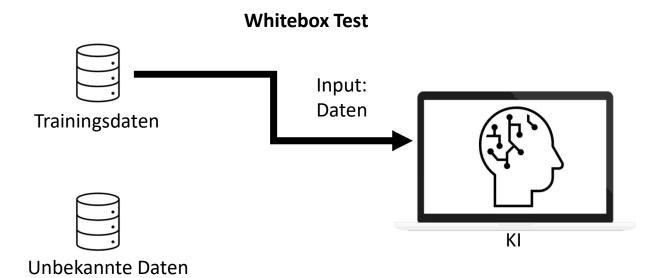
Einleitung Analyse Planung Design Durchführung Test Fazit





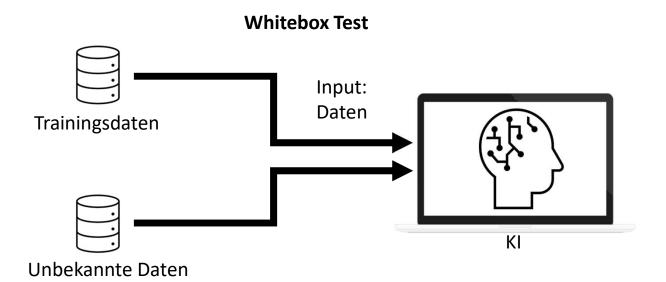






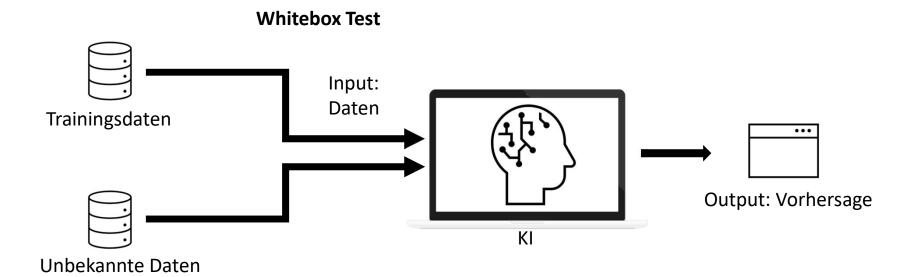






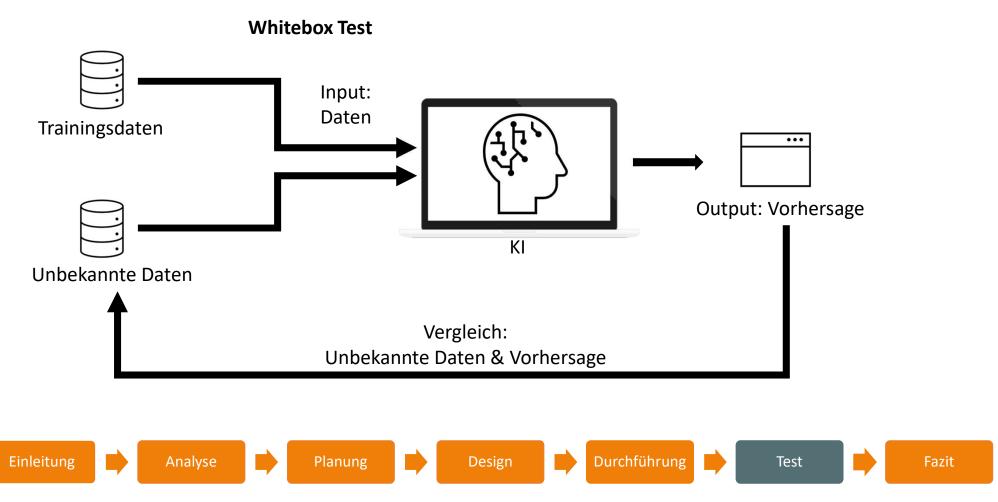




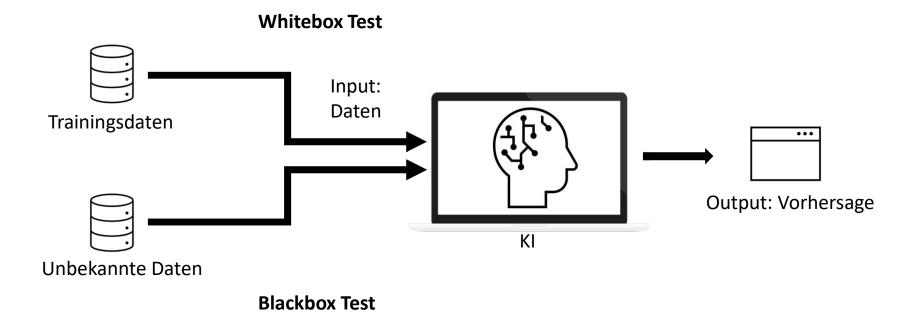
















Model: "Sequential\_Thema"

Layer	(type)	Output Sh	nape	Param #
Input	(Dense)	(None, 51	12)	2203136
Hidden	(Dense)	(None, 25	56)	131328
Output	(Dense)	(None, 31	L)	7967

Total params: 2,342,431

Trainable params: 2,342,431





Model: "Sequential\_Thema"

Layer	(type)	Output Shape	Param #
Input	(Dense)	(None, 512)	2203136
Hidden	(Dense)	(None, 256)	131328
Output	(Dense)	(None, 31)	7967

Total params: 2,342,431

Trainable params: 2,342,431

Non-trainable params: 0



Model: "Sequential\_Thema"

Layer	(type)	Output Shape	Param #
Input	(Dense)	(None, 512)	2203136
Hidden	(Dense)	(None, 256)	131328
Output	(Dense)	(None, 31)	7967

Total params: 2,342,431

Trainable params: 2,342,431





Model: "Sequential\_Thema"

Layer	(type)	Output Shape	Param #
Input	(Dense)	(None, 512)	2203136
Hidden	(Dense)	(None, 256)	131328
Output	(Dense)	(None, 31)	7967

Total params: 2,342,431

Trainable params: 2,342,431





Model: "Sequential\_Thema"

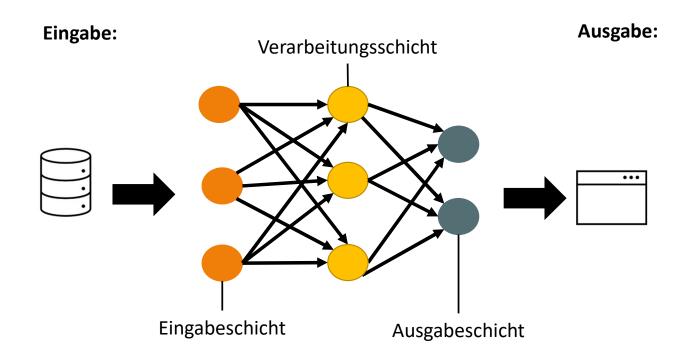
Layer	(type)	Output Shape	Param #
Input	(Dense)	(None, 512)	2203136
Hidden	(Dense)	(None, 256)	131328
Output	(Dense)	(None, 31)	7967

Total params: 2,342,431

Trainable params: 2,342,431

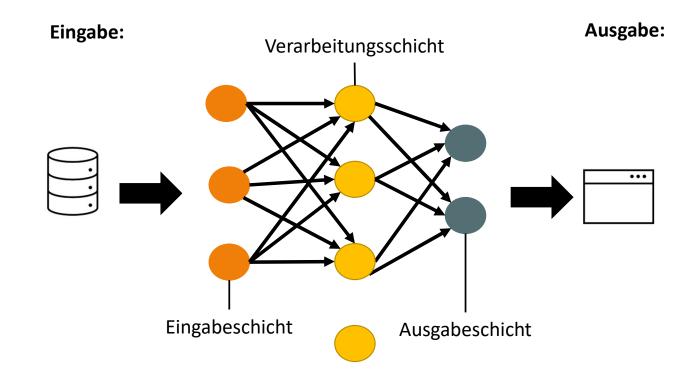




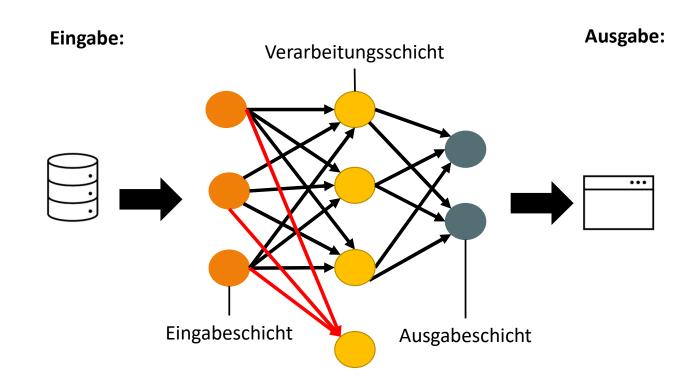






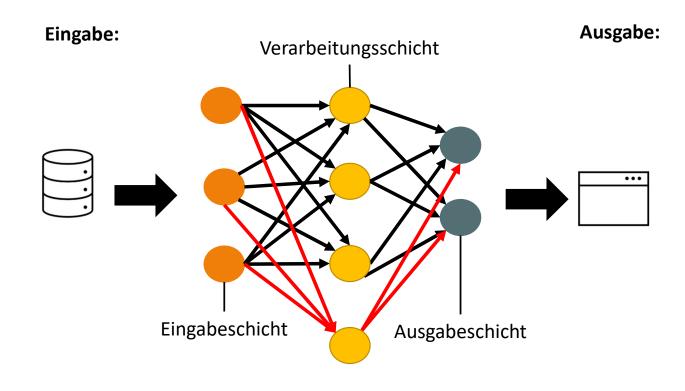










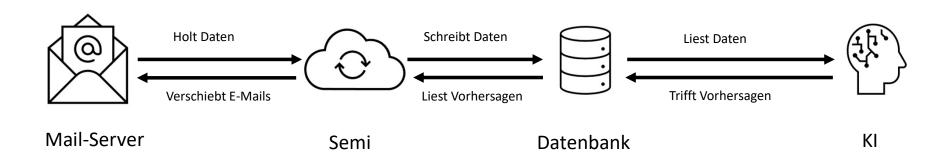






Einleitung Analyse Planung Design Durchführung Test Fazit

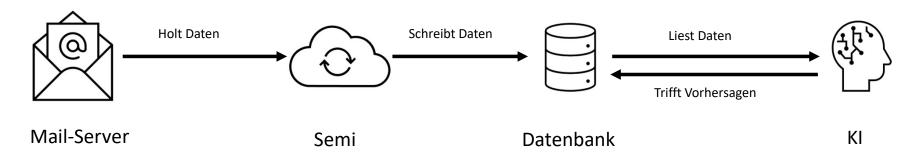








#### Test-System:

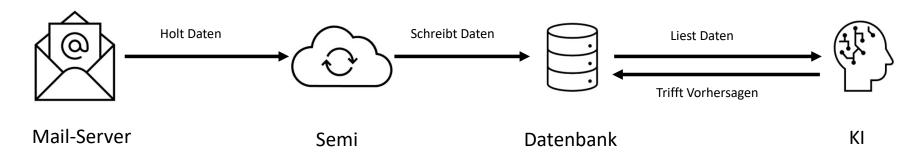


→ Semi verschiebt <u>keine</u> E-Mails



# — <u>•</u> — —

#### Test-System:

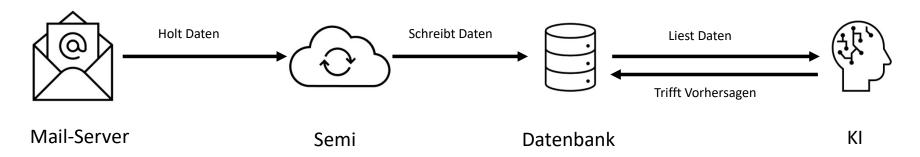


- → Semi verschiebt <u>keine</u> E-Mails
- → Training (Whitebox Test)





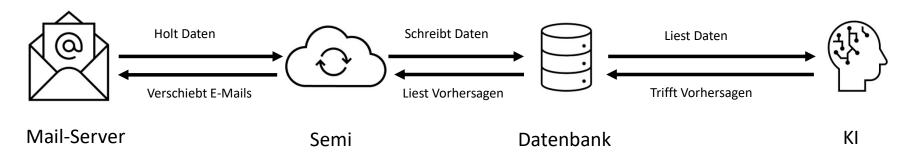
#### Test-System:



- → Semi verschiebt keine E-Mails
- → Training (Whitebox Test)
- → Unbekannte Daten (Blackbox Test)



#### Produktiv-System:



→ Semi verschiebt E-Mails











→ Spam: ca. 99%



Einleitung Analyse Planung Design Durchführung Test Fazit





→ Spam: ca. 99%

→ Themen: ca. 85% ✓

Einleitung Analyse Planung Design Durchführung Test Fazit





→ Spam: ca. 99%



→ Themen: ca. 85% ✓



Vorhersagen entsprechen den Vorgaben

Einleitung Analyse Planung Durchführung Design Fazit







- → Spam: ca. 99%
- → Themen: ca. 85% ✓
- Vorhersagen entsprechen den Vorgaben
- Wissenserwerb hat stattgefunden







- → Spam: ca. 99%
- → Themen: ca. 85% ✓
- Vorhersagen entsprechen den Vorgaben
- Wissenserwerb hat stattgefunden
- Blaupause für zukünftige KI-Projekte

# Ausblick & Lernerfolg





#### Ausblick & Lernerfolg



Umsetzung der meisten KI Projekte scheitern:

→ Implementierung des KI-Modells



#### Ausblick & Lernerfolg



#### Umsetzung der meisten KI Projekte scheitern:

→ Implementierung des KI-Modells



Quelle: https://towardsdatascience.com/colabcode-deploying-machine-learning-models-from-google-colab-54e0d37a7b09





B. Stull